

IMAGE CAPTIONING

Geração automática de descrições de imagem em linguagem natural

Vinicius Gomes Pereira

AGENDA

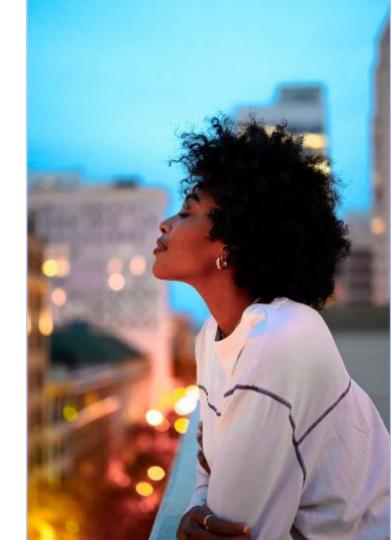
1. Convolutional Neural Networks (CNN)

2. Recurrent Neural Networks (RNN)

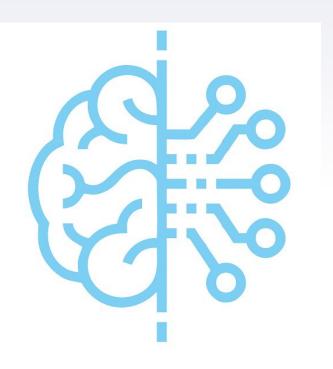
- a. Motivação
- b. RNN Model
- c. Tipos de RNN
- d. Language Model
- e. Sequence To Sequence Model
- f. Vanishing and Exploding Gradients.
- g. GRU e LSTM

3. Aplicação

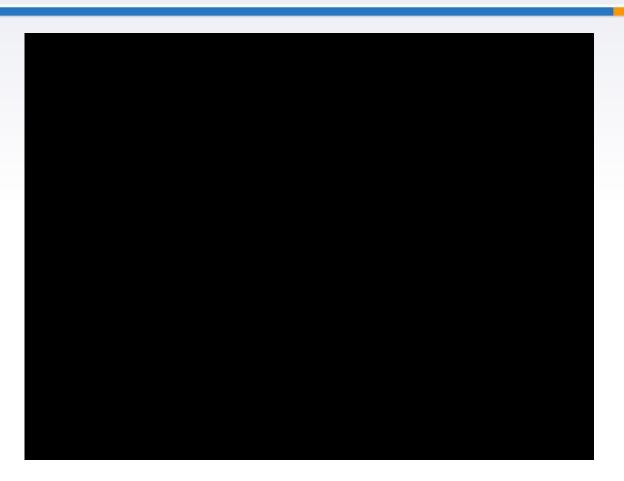
- a. Arquitetura
- b. Banco de Dados
- c. Código



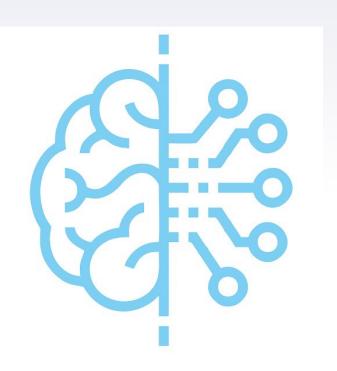
Convolutional Neural Networks



App de CNN



Recurrent Neural Networks



Motivação

1) Dados de natureza sequencial (texto, áudio, vídeo e séries temporais) [Idéia Temporal]

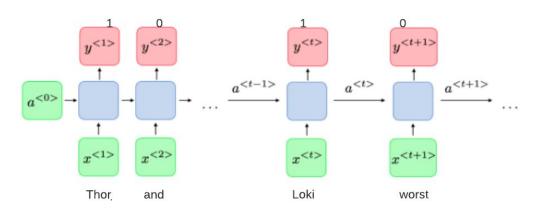
Algumas aplicações com dados sequenciais (seja como input ou output):

- a) Prediction problems
- b) Language Modelling and Generating Text
- c) Machine Translation
- d) Speech Recognition
- e) Generating Image Descriptions
- f) Video Tagging
- g) Text Summarization
- h) Other applications like Music composition

Exemplo (NER)

Dada uma frase, classificar extrair entidades de nomes (nomes de pessoas, organizações, países, etc)

- a) **Amazon** will allow corporate employees to work from home through June 2021. **Facebook** and **Twitter** also have told employees that they may remain as remote workers after the pandemic;
- b) Thor and Loki's worst Halloween ever.



Notação

 a) Para a t-ésima palavra do i-ésimo exemplo:

$$x^{(i)} < t > y^{(i)} < t >$$

b) Tamanho do i-ésimo exemplo:

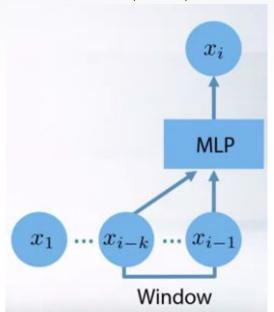
$$T_x$$
 T_z

Questão

- a) He said Teddy Roosevelt was a great president.
- b) He said teddy bears they're on sale.

Por que não um MLP?

- 1) Inputs e Outputs têm **tamanhos** diferentes
- 2) Não há compartilhamento de features em etapas do tempo
- 3) Número de pesos para serem estimados para um vocabulário pequeno é alto.



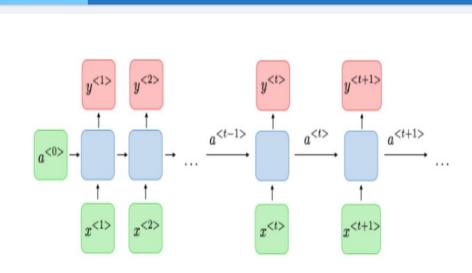
Quantos pesos existem na primeira camada de um MLP com as seguintes características:

- a) 100 hidden neurons
- b) Window length: 100
- c) Word Embedding size: 100

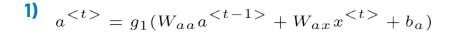
TOTAL: 1000100 > 1M parâmetros

100*100 inputs na primeira camada, com 100 de tamanho de embeddings, o que resulta em 1M de parâmetros. Além do vetor de bias com 100 parâmetros.

RNN Model

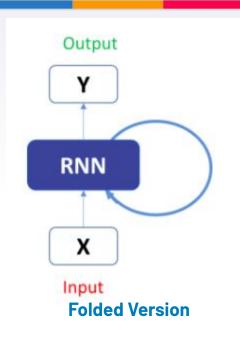


Unfolded Version



2)
$$\hat{y}^{< t>} = g_2(W_{ya}a^{< t>} + b_y)$$

Forma Simplificada

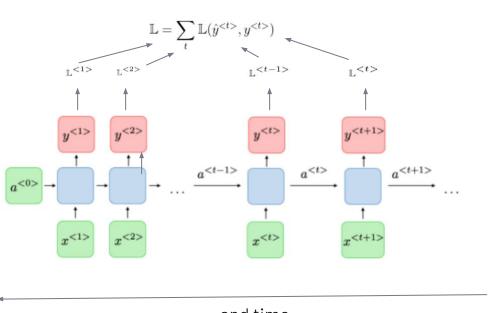


1)
$$a^{} = g_1(W_a[a^{}, x^{}] + b_a)$$

2)
$$\hat{y}^{< t>} = g_2(W_y a^{< t>} + b_y)$$

Backpropagation through time (BPTT) [1/3]

1) Deve-se calcular a derivada do erro, em relação a cada matriz de peso dos parâmetros.



Backpropagate through layers

... and time

Backpropagation through time (BPTT) [2/3]

Deve-se calcular a derivada do erro, em relação a cada matriz de peso dos parâmetros.

$$\frac{\delta L}{\delta W_{aa}}, \frac{\delta L}{\delta W_{ax}}, \frac{\delta L}{\delta W_{ya}}, \frac{\delta L}{\delta W_{ba}}, \frac{\delta L}{\delta W_{by}},$$

i)
$$\hat{y}^{} = g_2(W_{ya}a^{} + b_y)$$

ii)
$$a^{} = g_1(W_{aa}a^{} + W_{ax}x^{} + b_a)$$

$$\frac{\delta \mathbb{L}}{\delta W_{ya}} = \sum_{t} \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta \hat{W}_{ya}} \longrightarrow \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta W_{ya}} = \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta \hat{y}^{\langle t \rangle}} \frac{\delta \hat{y}^{\langle t \rangle}}{\delta W_{ya}}$$

$$\frac{\delta \mathbb{L}}{\delta W_{aa}} = \sum_{t} \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta \hat{W}_{aa}} \longrightarrow \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta W_{aa}} = \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta \hat{y}^{\langle t \rangle}} \frac{\delta \hat{y}^{\langle t \rangle}}{\delta a^{\langle t \rangle}} \frac{\delta a^{\langle t \rangle}}{\delta W_{aa}}$$

Backpropagation through time (BPTT) [3/3]

$$\frac{\delta \mathbb{L}}{\delta W_{aa}} = \sum_{t} \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta \hat{W}_{aa}} \longrightarrow \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta W_{aa}} = \frac{\delta \mathbb{L}^{\langle t \rangle}}{\delta \hat{y}^{\langle t \rangle}} \frac{\delta \hat{y}^{\langle t \rangle}}{\delta a^{\langle t \rangle}} \frac{\delta a^{\langle t \rangle}}{\delta W_{aa}}$$

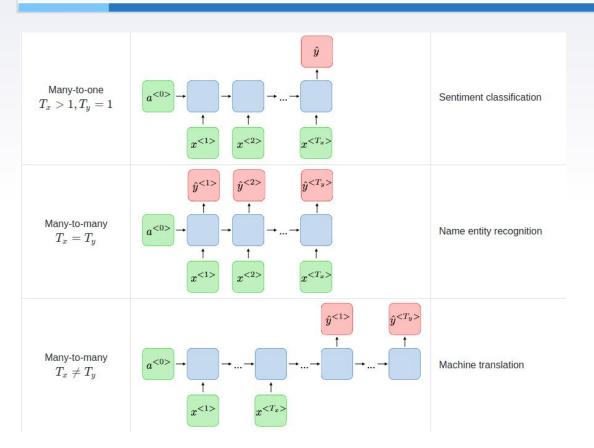
$$\left| \frac{\delta a^{\langle t \rangle}}{\delta W_{aa}} \right| = \sum_{k=0}^{t} \prod_{i=k+1}^{t} \frac{\delta a^{\langle i \rangle}}{\delta a^{\langle i-1 \rangle}} \frac{\delta a^{\langle k \rangle}}{\delta W_{aa}}$$

10

Tipos de RNN [1/2]

| Type of RNN | Illustration | Example |
|---------------------------|--|----------------------------|
| One-to-one $T_x=T_y=1$ | $ \begin{array}{c} \hat{y} \\ \uparrow \\ \hline x \end{array} $ | Traditional neural network |
| One-to-many $T_x=1,T_y>1$ | $ \begin{array}{c} \hat{y}^{<1>} \\ \uparrow \\ \downarrow \\ x \end{array} $ $ \begin{array}{c} \hat{y}^{<2>} \\ \uparrow \\ \downarrow \\ x \end{array} $ $ \begin{array}{c} \hat{y}^{} \\ \uparrow \\ \downarrow \\ \downarrow$ | Music generation |

Tipos de RNN [2/2]



Vanishing Gradients and Exploding Gradients

$$\frac{\delta \mathbb{L}^{\langle t \rangle}}{W_{aa}} \propto \sum_{k=0}^{t} \prod_{i=k+1}^{t} \frac{\delta a^{\langle i \rangle}}{\delta a^{\langle i-1 \rangle}} \frac{\delta a^{\langle k \rangle}}{\delta W_{aa}}$$

$$\left\| \frac{\delta a^{}}{\delta a^{}} \right\| > 1$$
 Cresce exponencialmente rápido. Podendo levar a exploding gradients

 $\left\| \frac{\delta a^{<\iota>}}{\delta a^{<t-1>}} \right\| < 1 \qquad \text{Decresce exponencialmente rápido.} \\ \text{Podendo levar a vanishing gradients}$

The cat, witch actually ate, ..., was full

The cats, witch actually ate, ..., were full

Gated Recurrent Unit (GRU) (intuição)

- 1) Solução para memória de curto prazo e solução para o problema de vanishing gradients;
- 2) Mecanismos internos chamados portões (update e reset gate) que podem regular o fluxo de informações
- 3) Se o reset gate for proximo de zero, ignora-se o estado anterior (permite que o modelo ignore informações que são irrelevantes pro futuro)
- 4) Update gate controla o quanto do passado é relevante no atual momento
- 5) Se houver pequena dependência temporal, **haverá reset gates ativos**. Se houver grande dependência temporal, haverá **update gates ativos**.

[Cho et al. 2014. On the Properties of Neural Machine Translation: Encoder-Decoder Approaches] [Chung et al. 2015. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling]

Gated Recurrent Unit (GRU) (modelo)

$$a^{< t>} = g_1(W_a[a^{< t-1>}, x^{< t>}] + b_a)$$
 Modelo Anterior

$$\tilde{c}^{< t>} = g_1(W_c[\Gamma_r^{< t>}] * c^{< t-1>}, x^{< t>}] + b_c)$$
 Reset Gate
$$\Gamma_r^{< t>} = g_2(W_r[c^{< t-1>}, x^{< t>}] + b_r)$$

$$c^{< t>} = \Gamma_u^{< t>} * \tilde{c}^{< t>} + (1 - \Gamma_u^{< t>}) * c^{< t-1>}$$

$$\Gamma_u^{< t>} = g_2(W_u[c^{< t-1>}, x^{< t>}] + b_u)$$
 Update Gate
$$\Gamma_u^{< t>} = g_2(W_u[c^{< t-1>}, x^{< t>}] + b_u)$$

$$\hat{y}^{< t>} = g_3(W_y c^{< t>} + b_y)$$

Long Short Term Memory (LSTM) (intuição)

- 1) Solução para memória de curto prazo e solução para o problema de vanishing gradients;
- 2) Mecanismos internos chamados portões (update, forget e output gate) que podem regular o fluxo de informações
- 3) Se o forget gate for proximo de zero, ignora-se o estado anterior (permite que o modelo ignore informações que são irrelevantes pro futuro) [Análogo ao Reset Gate]
- 4) Update gate controla o quanto do passado é relevante no atual momento
- 5) 2 estados (a,c) representam cada instante de tempo.

Long Short Term Memory (LSTM) (modelo)

$$ilde{c}^{< t>} = g_1(w_c[a^{< t-1>}, x^{< t>}] + b_c)$$

$$\Gamma_u = g_2(w_u[a^{< t-1>}, x^{< t>}] + b_u)$$

$$\Gamma_f = g_3(w_f[a^{< t-1>}, x^{< t>}] + b_f)$$
 Equações dos Gates (update, forget e output gate)
$$\Gamma_o = g_4(w_o[a^{< t-1>}, x^{< t>}] + b_o)$$

$$c^{\langle t \rangle} = \Gamma_u * \tilde{c}^{\langle t \rangle} + (1 - \Gamma_u) * c^{\langle t - 1 \rangle}$$

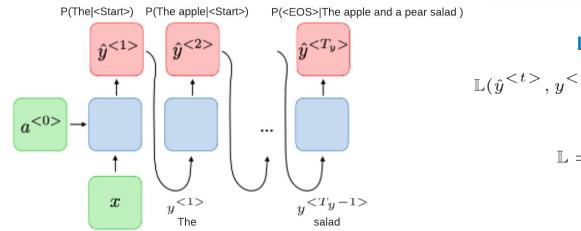
$$a^{\langle t \rangle} = c^{\langle t \rangle}$$

$$c^{\langle t \rangle} = \Gamma_u * \tilde{c}^{\langle t \rangle} + \Gamma_f * c^{\langle t-1 \rangle}$$
$$a^{\langle t \rangle} = \Gamma_o * c^{\langle t \rangle}$$

GRU LSTM

Language Model e Sequence Generation

- Calcular probabilidade de uma sentença, em relação a um determinado corpus.
- \square P(The apple and a pair salad) < P(The apple and a pear salad)
- P(The apple and a pair salad) = P(The | <Start>) P(Apple|The) P(and|The apple)...P(salad | The apple and a pair).P(<EOS>|The apple and a pair salad)

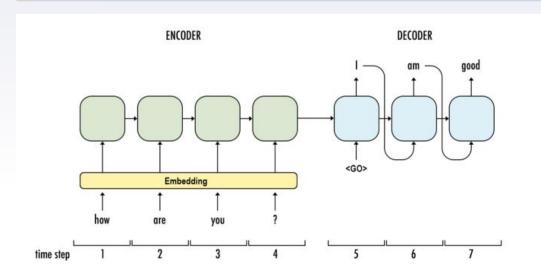


Loss Function

$$\mathbb{L}(\hat{y}^{}, y^{}) = -\sum_{i} y_{i}^{} \log(\hat{y}_{i}^{})$$

$$\mathbb{L} = \sum_{t} \mathbb{L}(\hat{y}^{}, y^{t})$$

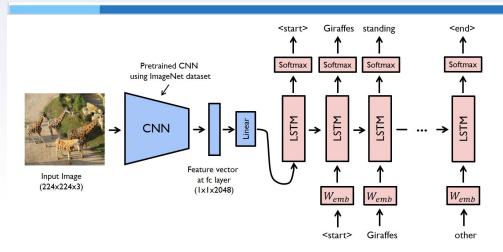
Sequence To Sequence Model



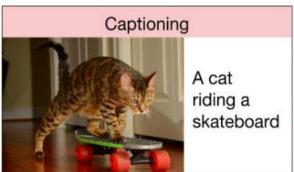
- Este tipo de arquitetura funciona para machine translation (no caso de em vez de responder a frase, a tradução
- Encoder tem como objetivo encontrar uma representação dos dados sequenciais do input.
- O **Decoder** utiliza os dados do Encoder de modo a gerar um texto que faça sentido.

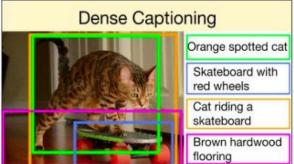
Esse tipo de estrutura é utilizada em **Image Captioning** mas de uma usando uma estrutura diferente para gerar o **encoder**.

Image Captionioning



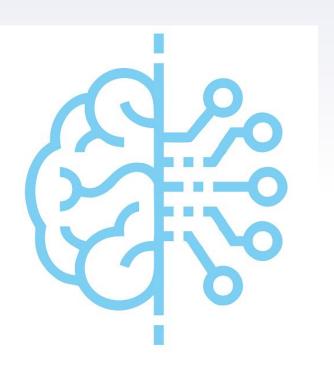






[PDF] Connecting Images and Natural Language, Andrej Karpathy, PhD Thesis, 2016

3 Aplicação Final



4 Dúvidas

